report

W&B 项目：https://wandb.ai/t2316463038-0/QHXX。

一、所有实验汇总

exp_name	env	env steps	末次平均回报	最大平均回报	单局峰值	W&B run id
cartpole	CartPole-v0	104978	200.0	200.0	200.0	dw270c2g
cartpole_lb	CartPole-v0	407018	151.0	200.0	200.0	rjwnz0l6
cartpole_lb_na	CartPole-v0	401477	200.0	200.0	200.0	43sceb3c
cartpole_lb_rtg	CartPole-v0	402162	200.0	200.0	200.0	oag0q4he
cartpole_lb_rtg_na	CartPole-v0	406042	200.0	200.0	200.0	7ucp4i6t
cartpole_na	CartPole-v0	102107	200.0	200.0	200.0	keh55qt8
cartpole_rtg	CartPole-v0	104073	200.0	200.0	200.0	7nxo0uh2
cartpole_rtg_na	CartPole-v0	104975	200.0	200.0	200.0	tlt5x5h8
cheetah	HalfCheetah-v4	500000	-237.0	-133.1	-110.4	9n2s3t7p
cheetah_baseline	HalfCheetah-v4	500000	61.1	148.6	187.7	4tydxfav
cheetah_baseline_bgs1	HalfCheetah-v4	500000	163.8	250.8	298.0	7rkx3iz0
cheetah_baseline_sd2	HalfCheetah-v4	500000	56.7	127.6	197.0	i0250395
cheetah_baseline_sd3	HalfCheetah-v4	500000	-88.0	97.8	181.6	ind61e8n
lunar_lander_lambda0	LunarLander-v2	437289	-106.6	83.2	313.4	amqcw0mq
lunar_lander_lambda0.95	LunarLander-v2	434946	-35.9	128.7	184.8	xoubvha8
lunar_lander_lambda0.98	LunarLander-v2	448460	-42.3	244.7	317.1	olywd78l
lunar_lander_lambda0.99	LunarLander-v2	442516	0.2	244.2	315.8	0xlsxkgk
lunar_lander_lambda1	LunarLander-v2	440826	-32.3	194.1	268.6	xyfl0iii
pend_t1	InvertedPendulum-v4	64880	517.0	1000.0	1000.0	bkcjnzmv
pend_t4	InvertedPendulum-v4	62833	63.2	207.6	332.0	gr6r0l0r
pend_t5	InvertedPendulum-v4	33538	56.3	225.5	384.0	nyob688v
pend_t6	InvertedPendulum-v4	63371	846.0	846.0	902.0	mam23khu
pend_u1	InvertedPendulum-v4	63977	1000.0	1000.0	1000.0	oxjwjk39
pend_u2	InvertedPendulum-v4	125550	1000.0	1000.0	1000.0	psvcfk4n
pendulum	InvertedPendulum-v4	507311	203.2	1000.0	1000.0	mc35ll8x
pendulum_tuned	InvertedPendulum-v4	65235	1000.0	1000.0	1000.0	luo95479

二、Experiment 1：CartPole-v0

每组 100 次迭代；小批量 b=1000、大批量 b=4000，对比 reward-to-go（-rtg）与优势归一化（-na）四种组合。

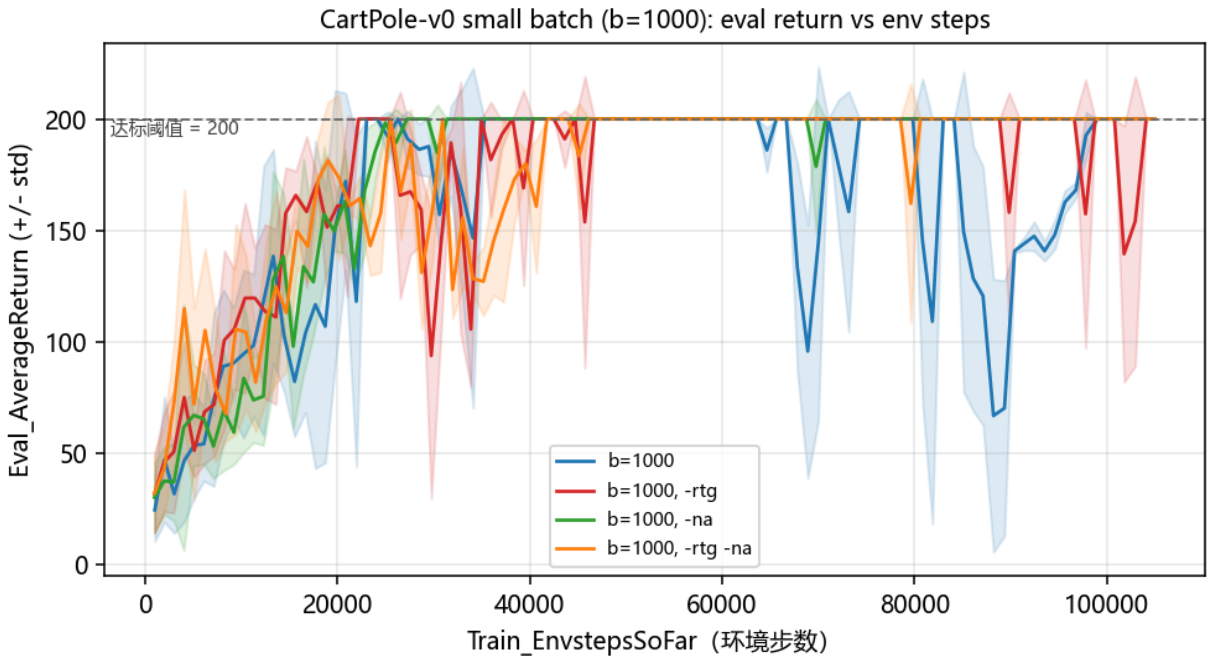


图 1 小批量 b=1000 的回报曲线

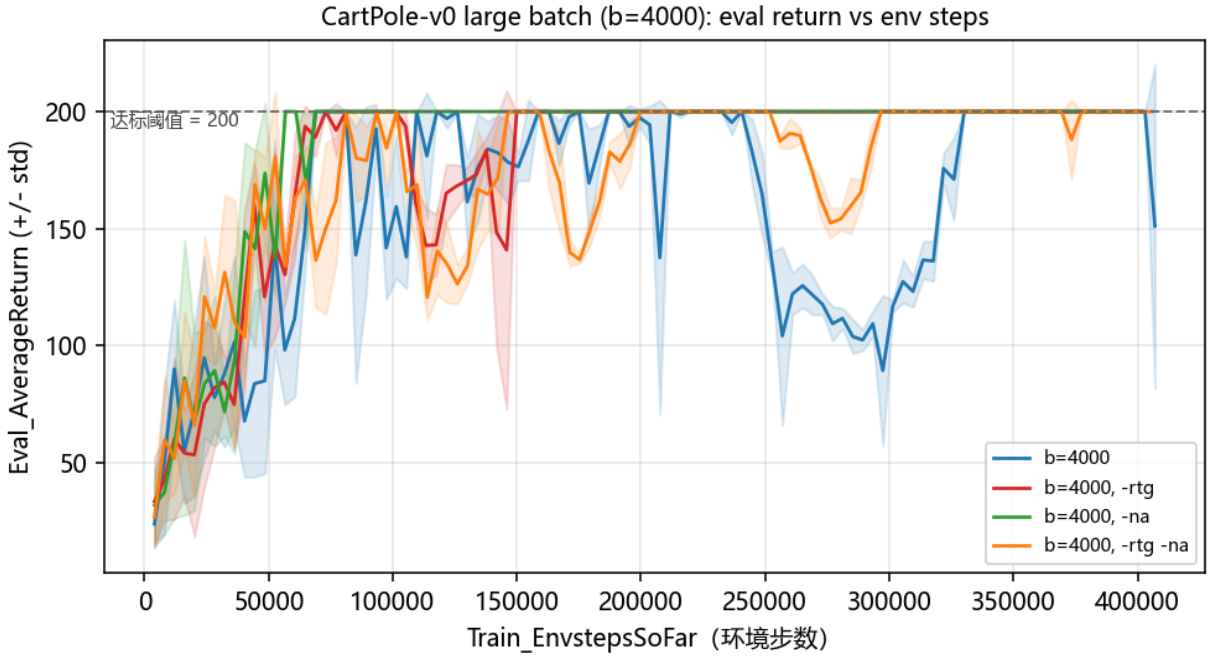


图 2 大批量 b=4000 的回报曲线

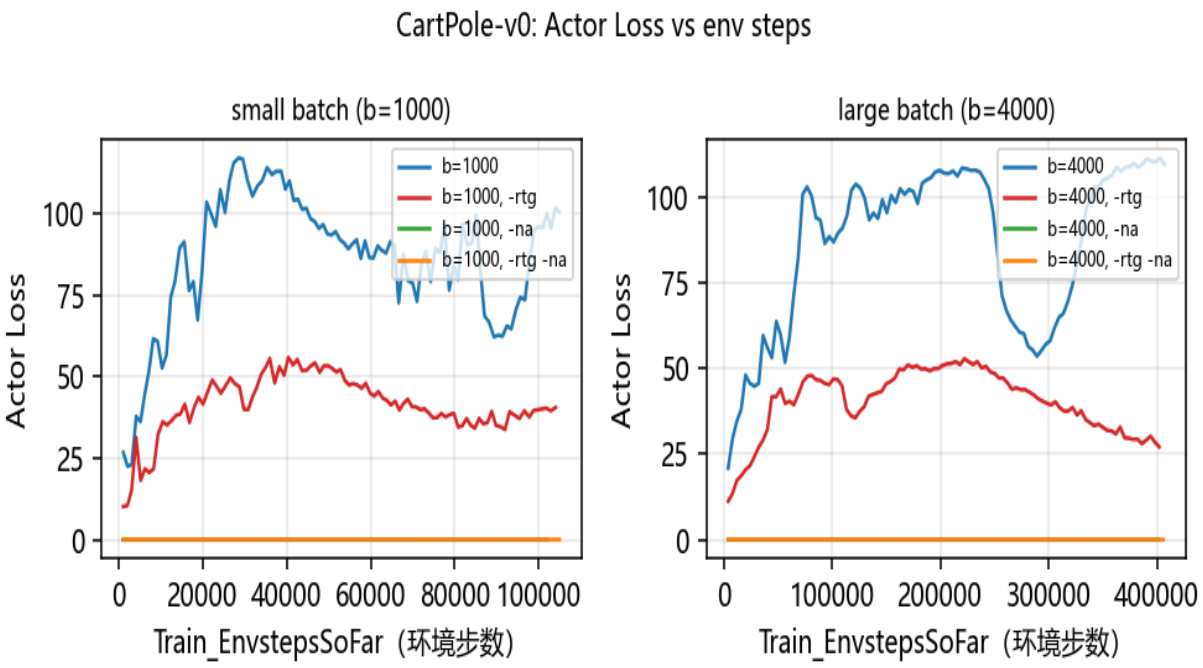


图 3 Actor Loss

实验配置	达标阈值	首次达标步数	末次平均回报	最大平均回报	单局峰值
b=1000	200	23,063	200.0	200.0	200.0
b=1000, -rtg	200	22,220	200.0	200.0	200.0
b=1000, -na	200	27,251	200.0	200.0	200.0
b=1000, -rtg -na	200	25,558	200.0	200.0	200.0
b=4000	200	68,708	151.0	200.0	200.0
b=4000, -rtg	200	73,035	200.0	200.0	200.0
b=4000, -na	200	56,756	200.0	200.0	200.0
b=4000, -rtg -na	200	93,467	200.0	200.0	200.0

超参数	b=1000	b=1000, -rtg	b=1000, -na	b=1000, -rtg -na
env_name	CartPole-v0	CartPole-v0	CartPole-v0	CartPole-v0
n_iter	100	100	100	100
batch_size	1000	1000	1000	1000
eval_batch_size	400	400	400	400
discount	1.0	1.0	1.0	1.0
learning_rate	0.005	0.005	0.005	0.005
use_reward_to_go	False	True	False	True
normalize_advantages	False	False	True	True
use_baseline	False	False	False	False
baseline_learning_rate	0.005	0.005	0.005	0.005
baseline_gradient_steps	5	5	5	5
n_layers	2	2	2	2
layer_size	64	64	64	64
seed	1	1	1	1

超参数	b=4000	b=4000, -rtg	b=4000, -na	b=4000, -rtg -na
env_name	CartPole-v0	CartPole-v0	CartPole-v0	CartPole-v0
n_iter	100	100	100	100
batch_size	4000	4000	4000	4000
eval_batch_size	400	400	400	400
discount	1.0	1.0	1.0	1.0
learning_rate	0.005	0.005	0.005	0.005
use_reward_to_go	False	True	False	True
normalize_advantages	False	False	True	True
use_baseline	False	False	False	False
baseline_learning_rate	0.005	0.005	0.005	0.005
baseline_gradient_steps	5	5	5	5
n_layers	2	2	2	2
layer_size	64	64	64	64
seed	1	1	1	1

结论

① -na 真正的价值是稳定性，不是速度，不管是大批量还是小批量，使用-na 的Actor Loss曲线值更低，说明波动更小，更稳定。

④ 这8个实验里，-na 和 -rtg 对达标速度的具体贡献确实不太好直接下定论。不过由Actor Loss 曲线可知，使用这两种策略均可以降低Loss，是算法变得更稳定。

⑤ batch size 的影响：batch size越大，每次梯度更新用的样本多，达标要多花 3 – 4 倍环境步数（vanilla 23,063 步 → 68,708 步），即样本效率更低。理论上曲线会越平滑，但在本实验中体现的并不明显。

四、Experiment 2：HalfCheetah-v4（神经网络 baseline）

discount=0.95、lr=0.01、-rtg、-b 5000、-eb 3000；对比是否使用 value baseline，以及减少 baseline步数。

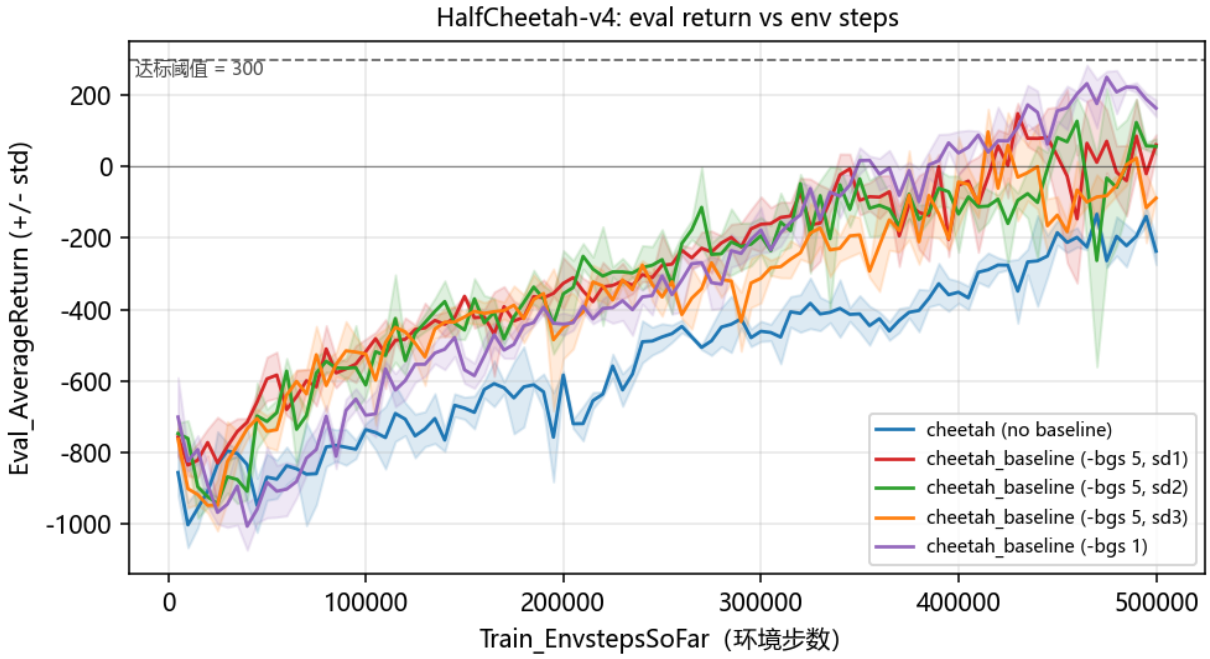


图 4 HalfCheetah-v4 回报曲线

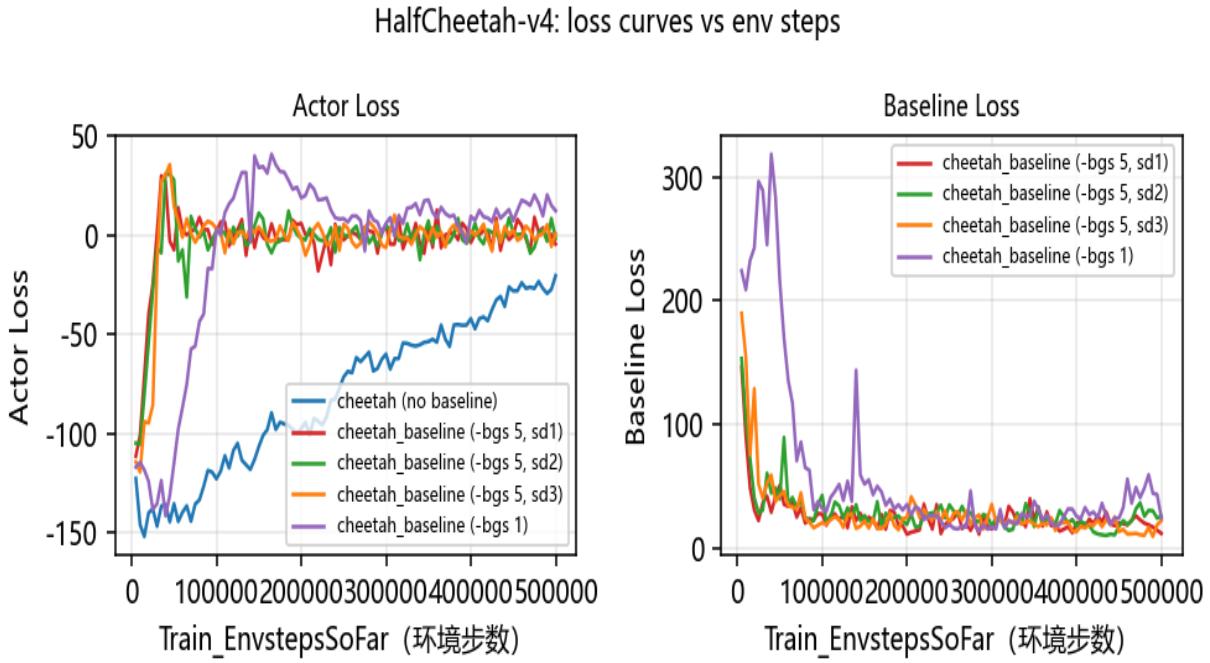


图 5 左：Actor Loss，右：Baseline Loss

实验配置	达标阈值	首次达标步数	末次平均回报	最大平均回报	单局峰值
cheetah (no baseline)	300	未达标	-237.0	-133.1	-110.4
cheetah_baseline (-bgs 5, sd1)	300	未达标	61.1	148.6	187.7
cheetah_baseline (-bgs 5, sd2)	300	未达标	56.7	127.6	197.0

实验配置	达标阈值	首次达标步数	末次平均回报	最大平均回报	单局峰值
cheetah_baseline (-bgs 5, sd3)	300	未达标	-88.0	97.8	181.6
cheetah_baseline (-bgs 1)	300	未达标	163.8	250.8	298.0

超参数	no baseline	-bgs 5 sd1	-bgs 5 sd2	-bgs 5 sd3	-bgs 1
env_name	HalfCheetah-v4	HalfCheetah-v4	HalfCheetah-v4	HalfCheetah-v4	HalfCheetah-v4
n_iter	100	100	100	100	100
batch_size	5000	5000	5000	5000	5000
eval_batch_size	3000	3000	3000	3000	3000
discount	0.95	0.95	0.95	0.95	0.95
learning_rate	0.01	0.01	0.01	0.01	0.01
use_reward_to_go	True	True	True	True	True
normalize_advantages	False	False	False	False	False
use_baseline	False	True	True	True	True
baseline_learning_rate	0.005	0.01	0.01	0.01	0.01
baseline_gradient_steps	5	5	5	5	1
n_layers	2	2	2	2	2
layer_size	64	64	64	64	64
seed	1	1	2	3	1

结论

① 可以看出最后5条曲线均没有到达达标阈值。

② 使用Baseline策略能有效提高回报。 不用 baseline 的 cheetah 末次平均回报 -237.0，最后 20 次迭代均值 -241.9（前 80 次 -616.8）；加 baseline后末次 61.1，最后 20 次均值 17.7（前 80 次 -368.1），两条曲线差距随时间稳定拉开。

③ 更换 seed 能改变最大平均回报，但是并不能使最大平均回报达到达标阈值。-bgs 5 的三个 seed，对应曲线的单局峰值分别是 187.7 / 197.0 / 181.6，均小于300。

④ 第二个和第五个比较，发现减小 baseline 梯度步数（-bgs 5 → 1）反而能提高平均回报：-bgs 1 末次 163.8、最大平均回报 250.8（-bgs 5 只有 148.6）。可能是因为每轮 5次 critic 更新会让 V(s) 过快贴近当前 batch 的target，等于在很小的样本上多跑几步，把优势里的噪声当成信号去拟合；减到 1 次后 critic 更新更保守。

⑤ 发现使用了 Baseline 策略的 Loss 曲线都在开始训练后非常迅速地回落到了 0 附近波动，其中 -bgs5 会比 -bgs1 回落速度更快，波动范围更小一些。

五、Experiment 3：LunarLander-v2（GAE lambda 搜索）

200 次迭代，b=2000、-eb 2000、-l 3、-s 128、-lr 0.001、discount=0.99、-rtg、--use_baseline，ep_len=1000，只改变 lambda。

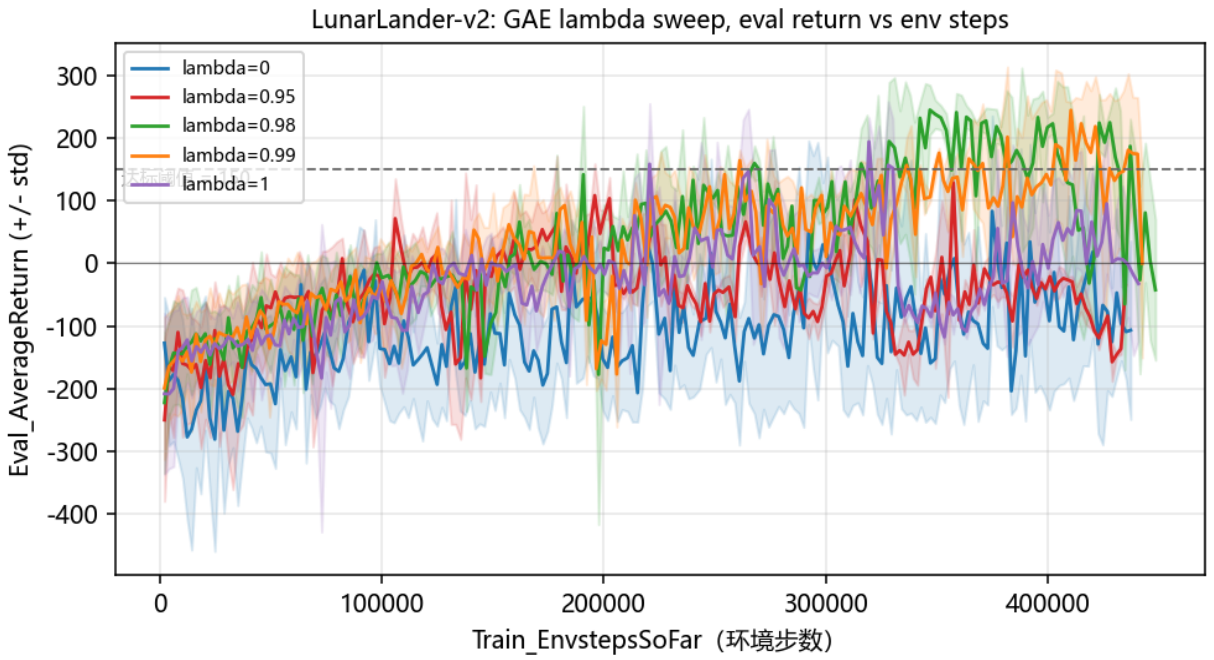


图 6 LunarLander-v2 的 λ 扫描

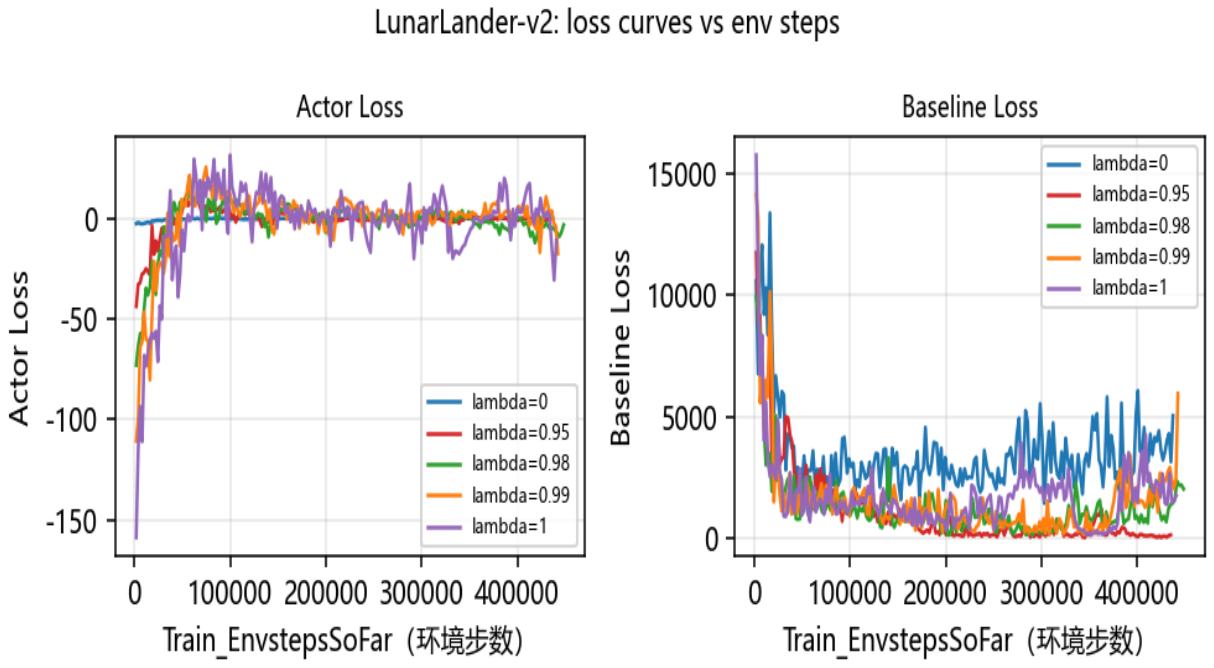


图 7 左：Actor Loss，右：Baseline Loss

实验配置	达标阈值	首次达标步数	末次平均回报	最大平均回报	单局峰值
lambda=0	150	未达标	-106.6	83.2	313.4
lambda=0.95	150	未达标	-35.9	128.7	184.8
lambda=0.98	150	267,868	-42.3	244.7	317.1
lambda=0.99	150	261,248	0.2	244.2	315.8

实验配置	达标阈值	首次达标步数	末次平均回报	最大平均回报	单局峰值
lambda=1	150	220,612	-32.3	194.1	268.6

超参数	lambda=0	lambda=0.95	lambda=0.98	lambda=0.99	lambda=1
env_name	LunarLander-v2	LunarLander-v2	LunarLander-v2	LunarLander-v2	LunarLander-v2
n_iter	200	200	200	200	200
batch_size	2000	2000	2000	2000	2000
eval_batch_size	2000	2000	2000	2000	2000
discount	0.99	0.99	0.99	0.99	0.99
learning_rate	0.001	0.001	0.001	0.001	0.001
use_reward_to_go	True	True	True	True	True
normalize_advantages	False	False	False	False	False
use_baseline	True	True	True	True	True
baseline_learning_rate	0.005	0.005	0.005	0.005	0.005
baseline_gradient_steps	5	5	5	5	5
gae_lambda	0.0	0.95	0.98	0.99	1.0
n_layers	3	3	3	3	3
layer_size	128	128	128	128	128
ep_len	1000	1000	1000	1000	1000
seed	1	1	1	1	1

结论

① λ=0：最大平均回报 83.2，标准差 58.1；
λ=0.95：最大平均回报 128.7，标准差 53.2；
λ=0.98：最大平均回报 244.7，标准差 81.8；
λ=0.99：最大平均回报 244.2，标准差 45.7；
λ=1：最大平均回报 194.1，达到 150 的迭代次数 4，尾部 50 次均值 -18.3、标准差 58.5。
② λ=0的单局峰值高达 313.4，远超 150，但单局峰值只说明某次评估里有一局运气极好，这证明该策略不稳定。所以判断达标必须用平均回报，不能用单局峰值。
③ λ=0.98 最大平均回报最大，但从 Loss 曲线可以观察到，没有那么 λ=0.95 的时候波动小，属于上限高，但稳定性稍差。
④ λ=1 只在中间少数几次迭代碰到 150，说明纯蒙特卡洛回报方差太大，模型并没有真正学会。

六、Experiment 4：InvertedPendulum-v4（超参数与样本效率）

默认配b=5000、learningrate=0.005

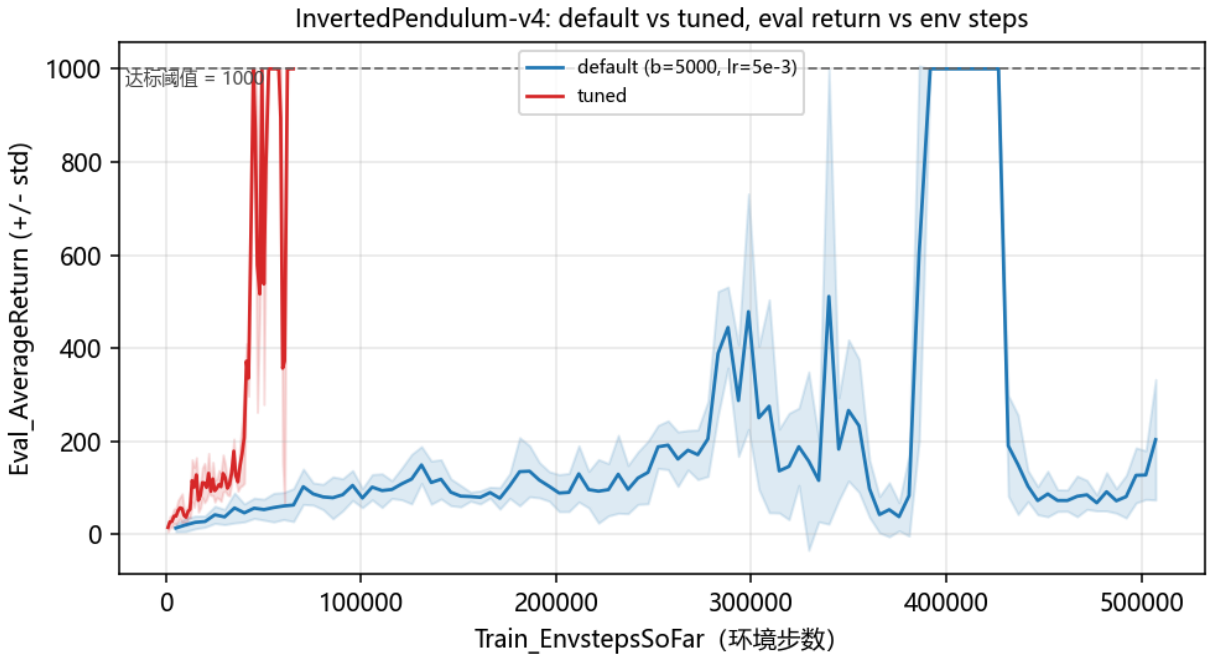


图 8 InvertedPendulum-v4：default 与 tuned

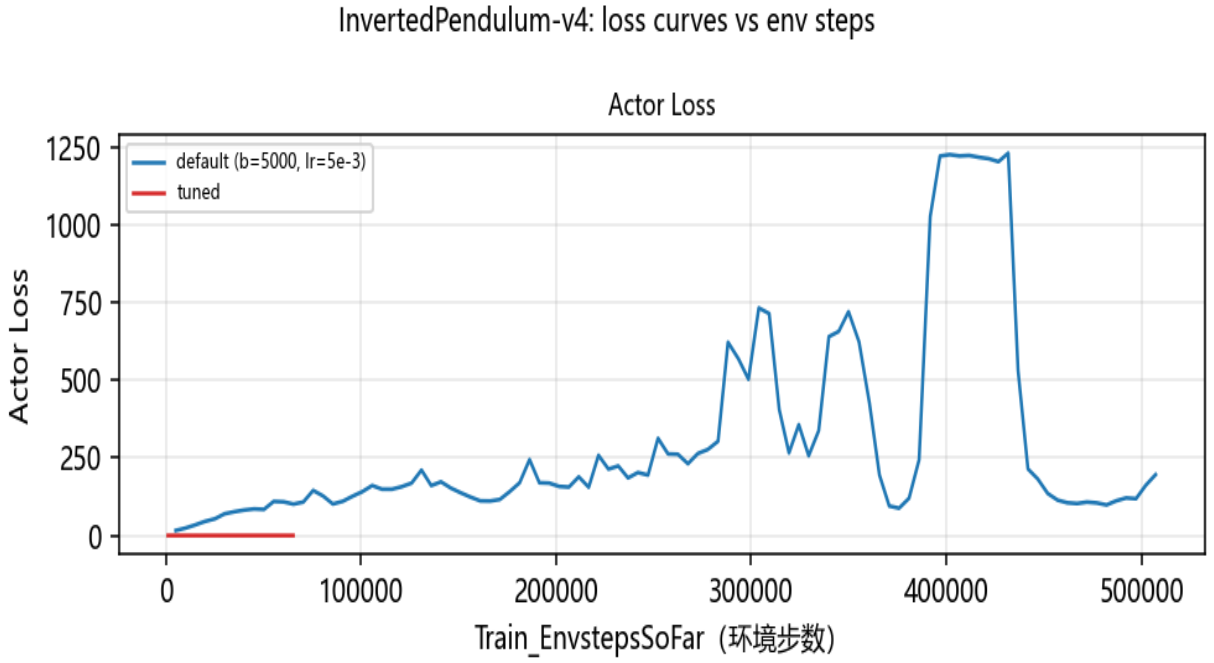


图 9 Actor Loss

实验配置	达标阈值	首次达标步数	末次平均回报	最大平均回报	单局峰值
default (b=5000, lr=5e-3)	1000	391,770	203.2	1000.0	1000.0
tuned	1000	44,784	1000.0	1000.0	1000.0

超参数	default (b=5000, lr=5e-3)	tuned
env_name	InvertedPendulum-v4	InvertedPendulum-v4

n_iter	100	60
batch_size	5000	1000
eval_batch_size	1000	1000
discount	1.0	0.99
learning_rate	0.005	0.02
use_reward_to_go	False	True
normalize_advantages	False	True
use_baseline	False	False
baseline_learning_rate	0.005	0.005
baseline_gradient_steps	5	5
n_layers	2	2
layer_size	64	64
seed	1	1

结论

① 两曲线首次穿过 1000时对应的横轴位置：44,784 vs 391,770，样本效率提升约 8.7 倍。
② default 在 30 万步附近曾到 1000，但随即掉回 100 上下，所以它的「最大平均回报」是1000.0，而「末次平均回报」只有 203.2。这又启发我们，虽然以最大平均回报为达标标准，但也不能只看它，要结合图像，实事求是。
③ reward-to-go 是必要条件——把 -rtg去掉（见下表pend_t6）后最大平均回报只有846.0，不到 1000；batch 需要适中——b=2000 变慢（59,984 步）、b=500直接不达标（225.5）；lr 不能激进——lr=0.05 不达标（207.6）。
④ discount 0.99 只改善，不是关键：把 γ 调回 1.0（pend_t1）仍然达标，只是从 44,784 步变为 48,040步（约 7% 差距）。
⑤ 单次运行的波动不可忽略：同一组超参（b=1000, lr=0.02, γ =0.99, -rtg -na, n_iter=60）重复跑两次，首次达标步数分别是 44,784（pendulum_tuned）与 28,694（ pend_u1），相差约 1.5 倍。所以样本效率提升 8.7倍这种结论应当看成量级结论，而不是精确倍数。

调参消融记录：以完整配置为基准，每次只改一个因素，观察达标情况。

配置	相对基准的改动	batch	lr	discount	rtg	na	首次达标步数	最大平均回报
pendulum_tuned	基准配置	1000	0.02	0.99	True	True	44,784	1000.0
pend_u1	同一配置重复运行	1000	0.02	0.99	True	True	28,694	1000.0
pend_u2	batch 1000 → 2000	2000	0.02	0.99	True	True	59,984	1000.0
pend_t1	discount 0.99 → 1.0	1000	0.02	1.0	True	True	48,040	1000.0
pend_t4	lr 0.02 → 0.05	1000	0.05	1.0	True	True	未达标	207.6
pend_t5	batch 1000 → 500	500	0.02	1.0	True	True	未达标	225.5
pend_t6	去掉 -rtg	1000	0.02	1.0	False	True	未达标	846.0